

Athena TTS — Clone giọng voiceover

Nhân bản giọng “neil” và nói đúng thoại trong clip ref

15/06/2026

1. Setup

Dùng một **giọng voiceover mới** làm mẫu nhân bản, cho 5 engine đọc **đúng câu thoại có trong clip ref**, rồi đo độ giống giọng gốc. Chạy CPU (Apple M4 Pro).

- **Clip ref:** refs/neil.wav (4.5s, trích từ file voiceover 727407__voiceoverneil).
- **Thoại (transcript clip ref, lấy bằng Whisper):** ``Ladies and gentlemen, welcome.``
- **Câu cho 5 engine đọc:** đúng câu trên $\Rightarrow$ so sánh “táo với táo” cùng nội dung.
- Bốn engine clone từ neil.wav; Kokoro dùng giọng cài sẵn (không clone) — làm mốc.

2. Cách đo

Trích *speaker embedding* bằng Resemblyzer (d-vector GE2E), tính **cosine similarity** giữa output mỗi engine và clip ref neil.wav (0–1; càng cao càng giống giọng gốc).

3. Kết quả (cùng câu với clip ref)

#	Engine	Cosine $\rightarrow$ neil	Độ dài (s)	Nhân bản giọng
1	IndexTTS2	0.951	3.6	Có
2	F5-TTS	0.876	4.0	Có
3	Chatterbox	0.873	4.0	Có
4	StyleTTS2	0.797	3.2	Có
–	Kokoro	0.517	2.5	Không (giọng cài sẵn)




Figure 1: Trục tung: cosine similarity với clip ref neil (0–1). Mỗi cột là một engine.

4. So sánh với câu ngắn khác

Cùng giọng ref neil, nhưng đọc hai câu khác nhau. Câu càng dài + trùng nội dung clip ref thì số đo càng ổn định (câu “See you next time.” chỉ ~1–2s nên nhiễu hơn).

Engine	“See you next time.”	“Ladies and gentlemen, welcome.”
IndexTTS2	0.825	0.951
F5-TTS	0.801	0.876
Chatterbox	0.699	0.873
StyleTTS2	0.751	0.797
Kokoro	0.482	0.517

5. Biểu đồ sóng (cùng câu với clip ref)




Figure 2: Trục hoành: thời gian (giây). Trục tung: biên độ tín hiệu (chuẩn hoá $[-1, 1]$). Hàng trên cùng (đen) là clip ref neil; các hàng dưới là 5 engine đọc cùng câu.